PROJECT PERFORMANCE REVIEW / 求职材料准备

Teacher Agent 测评数据分析报告

技术项目：面向高校数学教学的 Agent 组卷与试卷管理系统 | 报告基准日期：2026-10-12

核心结论：项目已建立从任务结果、工具调用到业务副作用的多层评测闭环；具有可信的固定用例集版本提升证据，但还不能将其解读为生产级稳定性或全新盲测泛化准确率。

92.75%	88.89%	413 PASS	7/7
Official Holdout V3.2.1	**Dev117 合法复评**	**当前确定性回归**	**三组专项业务验收**
64/69，通过率	104/117，离线复评	1 SKIP	跨批次，非统一总测

01 核心判断

- 最值得写进简历：固定 69 条 Official Holdout 从 25/69 提升至 64/69（+39 条，+56.52 个百分点）。
- 最能体现工程深度：Semantic Router、Tool Calling、Working Memory、Pending、多轮约束合并、Preview → Confirm、版本安全与失败恢复。
- 最能体现测试能力：Dev117 的首次真实 API 与经核验复评口径分离；用 Tool Trace、状态和数据库副作用对失败做归因。
- 最需要声明的边界：Holdout 是同一固定 69 条用例的重复测评，定向回归分批执行，未进行当前最新版全量独立盲测。

02 指标口径一览

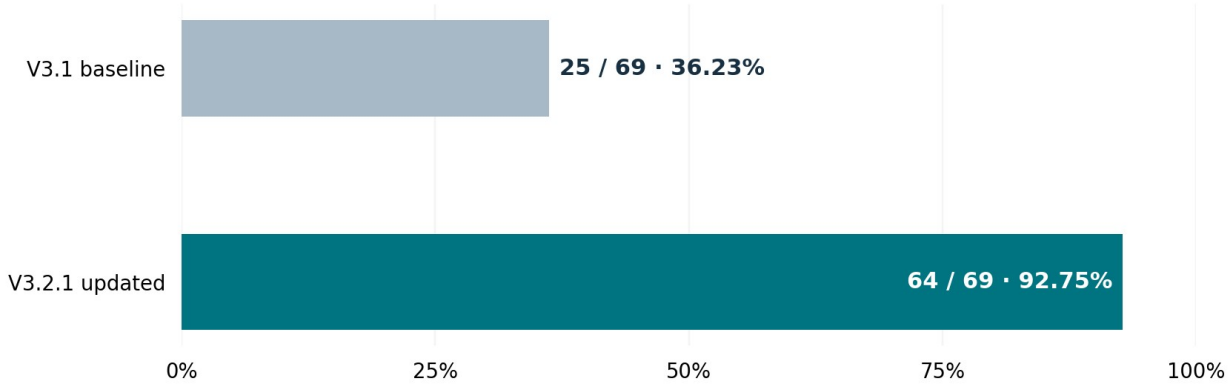
指标	结果	正确解读
Official Holdout	V3.1: 25/69; V3.2.1: 64/69	同一 69 条基准的迭代对比
Dev117	首次 97/117；复评 104/117	复评 +7 不是新模型重新推理
专项真实 API	3/3、2/2、2/2（合计 7/7）	不同时间的定向业务验收
确定性回归	413 PASS / 1 SKIP	代码测试数，不是 413 条 LLM 场景
数据集资产	300 条评测记录（阶段记录）	含重复/待审记录，非 300 独立盲测

优先级：求职简历应突出「工程方案 + 真实可复现的结果」，减少单纯堆砌“准确率”“成功率”等容易混淆的指标。

METHOD / 结果层与版本层

03 真实模型评测结果

Official Holdout · 最主要的迭代证据



固定同一组 69 条 Official Holdout：V3.1 初次 25/69（36.23%）→ V3.2.1 复测 64/69（92.75%）；增加 39 条通过，提升 56.52 个百分点；已通过用例无回退，Provider Failure 为 0。

统计限制：虽然 V3.2.1 执行时冻结 Runtime、Prompt、Fixture、Grader 及重试策略，但由于使用同一已知 69 条用例进行迭代，不能以“未见过的 Holdout 92.75%”宣传。

Dev117 · 首测和离线复评不可混写

口径	分子/分母	比率	说明
首次真实 API	97 / 117	82.91%	原始执行结果；不可修改
合法离线复评	104 / 117	88.89%	基于历史 Trace 纠正已核验评分误判
两口径差值	+7 条	+5.98 pp	属于评分复核增量，非模型新能力提升

其他阶段性测试

测试集	阶段记录	适用范围
Golden Smoke	17/20（85.0%）	固定核心流程的真实模型冒烟测试
Acceptance v1	20/20（100%）	核心业务功能验收
Failure Injection v1	20/20（100%）	故障注入与异常边界
最新版确定性回归	413 PASS / 1 SKIP	代码级回归；不可与 LLM 任务通过率相加

注：本页 Acceptance、Failure Injection、Golden Smoke 及确定性回归采用项目阶段性记录；未在本次报告生成过程中重新运行原始 Runner。

DIAGNOSTICS / 诊断层

04 工具可靠性、开销与风险

三组定向真实 API（跨时间验收）

模块	Case / 成绩	技术价值
上下文指代与失败恢复	T04、T05、T06；3/3 业务语义通过	可信焦点校验、路由纠偏、Preview 去重、候选不足止损
Pending 约束合并	EVAL-073、078；2/2 PASS	同轮题数/总分显式约束优先于旧 Pending，保护章节
只读查询可靠性	EVAL-186、188；2/2 PASS	一次全卷读取、数据库题型计数、隔离修改门禁

严格口径提醒：T05 的候选不足属于正确业务澄清，但在旧严格预期中曾不计通过；3/3 指业务语义口径，不能改写旧冻结成绩。

模型调用与 Token（V3.2.1 Official Holdout）

指标	数值	衍生解读
调用模型次数	163 次	每条 69 例平均 2.36 次；仅作总批次均值
输入 / 输出 Token	774,001 / 16,538	输入占总 Token 约 97.91%
合计 Token	790,539	平均约 11,457 Token / 测试记录
零模型调用案例	21 / 69（30.43%）	体现确定性处理路径；不等于成本节省率

技术推论：输入 Token 占比高，可继续观察 Prompt/工具上下文大小与调用轮数；但在缺少版本对照和单任务成本基线时，不宣称“Token 节省 XX%”。

尚未解决的真实风险

- V3.2.1 Official Holdout 未通过的 5 条：EVAL-059（难度契约）、066（误澄清）、068（路由）、145（地址歧义）、267（暂停请求被误当生成）。
- 当前仅有分批定向复测，未对最新所有修复版本做完整、全新盲测；不能声称整体 100% 或“无业务副作用”。
- 尚无统一并发压测、生产流量监控、端到端 P95 延迟与故障恢复时间统计，不应包装为生产级 SLA。

CAREER / 技术亮点与表达

05 面向 AI Agent 工程岗位的简历写法

推荐：放在「项目经历」而不是「科研成果」

项目名称：Teacher Agent｜面向数学教学的智能组卷与试卷管理系统（个人工程项目）

技术栈：Python、FastAPI、React、SQLite、LLM Tool Calling、Agent Runtime。

- 独立设计并实现基于 Semantic Router、Tool Calling 与 Working Memory 的教学 Agent，支持题库检索、约束组卷、试卷读取及多轮局部修改，实现自然语言请求到受控业务工具的执行闭环。
- 构建 Pending 状态管理与 Preview → Confirm 双阶段修改机制，结合 Paper Version 校验、显式约束优先级、幂等指纹及有界失败恢复，降低多轮换题、调分和组卷过程中的误操作风险。
- 建设覆盖组卷、多轮修改、工具失败与指代歧义的自动化评测体系（累计 300 条用例记录）；通过 Tool Trace、结构化断言和数据库副作用核验定位 Runtime 失效边界。
- 围绕路由、上下文状态及工具调用可靠性迭代，固定 69 条 Official Holdout 通过数由 25/69 提升至 64/69（36.23% → 92.75%，+56.52 个百分点）；另在 117 条真实 API 测试中首次通过 97 条，经离线复核为 104 条。

一页简历：压缩到 3 行时的取舍

- 第一行写架构与用途：Router / Tool Loop / Working Memory + 组卷、修改功能。
- 第二行写关键工程难点：Pending / Preview→Confirm / 版本安全 / 幂等恢复。
- 第三行写有证据的结果：69 例固定集 25→64 与 117 例首测 97/117；如版面不足，二选一优先写 Holdout 版本提升。

建议保留 / 不建议使用的简历表述

建议保留	不建议写（原因）
“固定 69 条评测通过率由 36.23%提高到 92.75%”	“全新盲测准确率 92.75%”（不是未见过的数据集）
“构建 300 条自动化评测用例记录”	“300 条独立用例 100%通过”（重复与测试状态不支持）
“413 项确定性测试通过”	“413 条 Agent 任务成功”（技术口径错误）
“保障操作必须经 Preview→Confirm”	“零误操作 / 生产级稳定”（证据不足）

面试时应能够说明

为什么 Agent 路由必须有确定性保护？如何区分用户显式约束与 Pending 继承值？Preview 如何保证幂等、版本一致性与未确认不落库？为什么 Dev117 的离线复评不是一次模型提升？

简历策略判断：对于校招或初级 AI Agent 开发岗位，最有区分度的是“业务状态安全 + 真实评测归因”，不是把单一通过率刷到 100%。

APPENDIX / 数据台账

06 数据出处与复现边界

优先可核验来源

- Official Holdout：official_holdout_v3_2_1_69_second_report.md；原始报告 tests/evals/reports/official-holdout-v3.2.1-69-second-20261006T045441Z.json；冻结 Git HEAD：f8d9b013fe6b4658a0a507159f24b7ebcbd030d6。
- Dev117：v3_2_dev117_failure_audit_evidence.md / .json；原始执行 97/117，合法离线复评 104/117；13 条历史失败保留并单独追踪。
- EVAL-073 / 078 定向真实 API：tests/evals/reports/pending-multifield-targeted-live-20261011T072303Z-d25888.json（2/2 PASS）。
- EVAL-186 / 188 定向真实 API：tests/evals/reports/readonly-186-188-targeted-live-20261012T024303Z-c7cf97.json（2/2 PASS）。
- T04 单条定向复测：tests/evals/reports/contextual-question-reference-api-validation-v4-20261011T061531Z.json（1/1 PASS）；T05/T06 为更早批次证据。

数字准确性审查清单（投递前使用）

- 分母清晰：69 条 Official Holdout / 117 条 Dev API / 413 条确定性代码测试，绝不混用。
- 时间清晰：早期官方版本比较 ≠ 当前全部修改后的统一最新总测。
- 收益清晰：通过率提高 56.52 个百分点（pp），而非“提高 56.52%”。
- 归因清晰：Dev97→104 来自合法离线复评，不是新跑一次模型产生的 7 条提升。
- 场景清晰：若在简历写 300 条用例，注明是构建记录，面试应能解释重复、Dev/Holdout 与 Golden Smoke 划分。
- 安全清晰：典型场景已验收，不意味着尚未评测场景不存在修改风险。

报告结论与下一步

建议冻结现有评测报告与对应 commit，保存一页项目架构图、两条典型失败 Trace（如 EVAL-073 与 EVAL-188）和一次 Preview/Confirm 演示。用这三类证据解释“做了什么、为什么这样设计、如何证明有用”，比继续提升零散测试通过率更能提升简历和面试说服力。

资料说明：官方 Holdout 汇总和 Dev117 审计来源为已留存的项目报告；最近三次专项验收、413 PASS 与数据集规模等由本次会话及项目阶段记录提供，未现场重新运行项目仓库代码。所有结果按其来源与版本边界呈现。